

TODO

张景铭、TODO、TODO、TODO

复旦大学计算与智能创新学院

大数据分析技术 课程报告 组号: 5

2026 年 6 月 26 日

摘 要 TODO

关键词 TODO

1 研究背景和意义

音乐演奏建模旨在从符号乐谱 (MIDI) 生成具有人类演奏特征的声音, 是计算音乐学与音乐信息检索领域长期被关注的核心任务之一^[5]。早期实践依赖采样合成器与基于规则的合成器: 前者按音高与力度查表回放预录音片段, 后者按 KTH 等规则系统^[7] 从乐谱推导力度与时值的微调; 这两类方法都能产出可听的音频, 但难以体现演奏者真正的微观控制 (如乐句轮廓的细微塑形、力度的连续渐变、起音的瞬态特征、句尾的弹性放缓), 输出常带有明显的机械感, 与真人演奏在听感上有较大差距。

近年来, 端到端的神经音频合成方法被广泛探索, 它们绕过显式的中间表征, 直接从乐谱或文本生成波形, 在拟合能力上有显著进步; 但由于训练目标与音频原始波形空间高度耦合, 这类方法的可解释性与可控性较弱, 也较难复用为下游音乐编辑工具的中间层。一个折中思路是将整套生成链路拆为两段: 先由乐谱预测连续的演奏控制信号 (帧级基频 f_0 与帧级振幅 amp), 再由控制信号经物理或谐波合成器渲染为波形。这条技术路线把音乐时序规律 (前段) 与声学物理规律 (后段) 解耦, 在保持端到端可学习性的同时显著提升了可解释性, 也使得每段模块可被独立评测与替换。

本项目以从 MIDI 直接生成具有音乐表现力的音频为整体目标, 采用上述两段式路线。整套系统先由乐谱预测帧级 (f_0, amp) , 再由 (f_0, amp) 经谐波合成与相位连续合成渲染为波形, 前者表征音乐时序规律, 后者表征声学物理规律。演奏信息模型把稀疏离散的乐谱事件翻译成稠密连续的控制信号, 是整套系统中承上启下的关键环节, 其预测精度直接决定下游音色合成的质量上限, 也直接关系整套端到端系统的可用性: 一旦控制信号丢失了演奏者本应有的乐句呼吸与力度起伏, 后续合成器再精细也无法补救。因此, 如何在 MIDI 的强约束之下, 用足够灵活的序列模型刻画出富有表现力的 (f_0, amp)

曲线,是整个端到端流程的核心难题之一。

2 研究目标和研究内容

研究目标: 给定 MIDI 乐谱, 预测真实演奏对应的逐声部帧级基频曲线 $f_0(t)$ 与振幅曲线 $\text{amp}(t)$, 帧率 100 Hz。模型应当具备如下三方面能力: 第一, 能从离散稀疏的音符序列中读出连续稠密的演奏控制意图, 而非简单地把音符 onset/offset 复刻到帧级网格; 第二, 能同时利用过去与未来的乐谱上下文, 覆盖单音局部、乐句中段、乐句首尾三种时间尺度上的演奏惯例; 第三, 用一套统一的架构同时适配单声部与多声部输入规模, 并预留沿声部维作用的可选交互通道, 以便检验同时发声的其他声部是否真正提升预测能力。

研究内容: (1) 设计可量化音乐时序语境的 20 维输入特征空间, 覆盖单音层、局部旋律层、乐句结构层三个时间尺度, 并以乐器族独热向量作为跨层统领, 让模型在编码阶段同时获得显式的音乐先验与隐式的统计先验。(2) 构建一套统一骨干, 用双向 Mamba 与双向 GRU 串联捕获长程时序依赖, 中间预留沿声部维作用的跨声部交互模块, 在需要时能依据同时发声的其他声部对本声部表示作再加权; $S = 1$ 时该模块退化为恒等映射, 整套架构在单声部与多声部输入下统一工作。(3) 在 URMP^[10]、Bach10^[11]、PHENICX-Anechoic 与 TRIOS 四个公开数据集所覆盖的真实演奏数据上, 评估帧级 f_0 的原始音高准确率与帧级振幅的 Pearson 相关性, 并用多随机种子配对检验衡量跨声部交互的真实增益。(4) 分析模型在不同乐器族上的预测能力差异, 把预测残差与各乐器的发声物理 (颤音、气压、弓压) 相关联, 为后续音色合成在乐器与织体层面上的差异化建模提供依据。

3 相关工作 (同类研究进展)

3.1 基于规则的演奏建模

基于规则的路径起源于 20 世纪 80 年代瑞典皇家理工学院 (KTH) 的演奏研究项目。Friberg 与 Sundberg 等人在 30 余年时间里逐步积累了一套数十条规则的系统, 用以刻画演奏者从乐谱结构中可推导的表情调整, 涵盖乐句轮廓的弧度、和声张力对应的力度强调、终止式的弹性放缓、滑奏与颤音的触发条件等^[7]; Director Musices 软件即为此系统的工程化实现, 默认开启 12 条最具代表性的规则, 是这一路径最完整的实践产物。Juslin、Friberg 与 Bresin 在 2002 年进一步提出 GERM 模型^[6], 把演奏中的表情来源拆为生成规则 (Generative rules, G)、情感表达 (Emotional expression, E)、随机波动 (Random fluctuations, R) 与运动学原理 (Motion principles, M) 四个相互独立、可独立度量、可独立证伪的分量, 至今仍是该领域被广泛援引的理论框架。Cancino-Chacón 等

人 2018 年的综述^[5] 对计算演奏建模方法做了系统的对比分析, 指出基于规则的方法在可解释性与可控性上有不可替代的优势, 但其代价是对专家先验的强依赖与对新乐器、新风格的迁移困难, 不易直接接入数据驱动的建模流程。

3.2 基于深度学习的演奏建模

数据驱动的演奏建模近年随深度学习的发展迅速演进, 大致可分为端到端与分层两条思路。端到端一类直接学习从符号到波形的映射, 典型代表是可微合成器 DDSP^[1]: 它把信号处理算子 (加性合成器、滤波器、混响等) 嵌入神经网络, 让控制参数到音频的整条链路保持可微, 既保留了 DSP 的可解释性, 又获得了神经网络的拟合能力。其分层扩展 MIDI-DDSP^[2] 进一步把整条链路解耦为 MIDI 层、演奏层、合成层三个层次, 用户可以在演奏层显式干预力度、起音、颤音深度等表情参数, 实现细粒度可控的演奏生成。在符号层面对演奏表情建模的代表性工作包括: VirtuosoNet^[3] 用分层 RNN 同时建模钢琴演奏的力度曲线与微观时值偏移, 在测度量上接近真人演奏; DEXter^[4] 则使用扩散概率模型在连续表情参数空间中生成钢琴演奏, 支持知觉特征引导的演奏风格转移。这些工作总体上聚焦于端到端的拟合能力或符号层面的演奏控制, 而对中间表征 (f_0 , amp) 是否能在符号到音频之间被独立、可靠地预测的边界缺乏系统刻画, 也少有针对乐器族差异的物理层面解释。本文正是在这一中间表征上展开系统分析。

3.3 数据集与评测

公开可用的多轨同步古典室内乐数据集是本任务的基础。URMP 数据集^[10] 由罗切斯特大学发布, 包含 13 种乐器、44 段室内乐, 提供高质量的分轨录音、MIDI 乐谱与帧级 f_0 标注, 是研究 MIDI 到音频映射的最常用基准之一。Bach10 数据集^[11] 由西北大学发布, 包含 10 段巴赫四声部圣咏, 每段都有 4 件乐器的独立录音, 适合用作跨数据集泛化测试。在评测口径上, 帧级 f_0 通常以原始音高准确率 (Raw Pitch Accuracy, RPA, 在 50 cents 之内计为正确) 评估, 帧级振幅以预测与真值序列的 Pearson 相关系数评估 (线性域与对数域两种), 部分文献还会报告对数域 RMSE。帧级 f_0 的提取通常采用 CREPE^[8] 或 pYIN^[9] 两种工具, 二者在干净录音上接近一致, 在乐句末尾的弱信号段 CREPE 略稳。本文以 RPA 与 Pearson 两项主指标做评测, f_0 标注采用 CREPE 提取再以数据集自带 ground-truth 校正的方案。

4 研究方法

4.1 数据集

4.1.1 数据获取

本文使用 URMP^[10]、Bach10^[11]、PHENICX-Anechoic 与 TRIOS 四个公开数据集。URMP 由罗切斯特大学发布, 包含 44 段古典室内乐, 共 13 种乐器, 提供高质量分轨录音、MIDI 乐谱与帧级 f_0 标注; Bach10 由西北大学发布, 包含 10 段四声部巴赫圣咏, 每段都有 4 件乐器的独立录音; PHENICX-Anechoic 提供无混响条件下的多声部古典片段, 含弦乐与管乐多种编制; TRIOS 是更新的三重奏数据集, 进一步补充小编制场景。四个数据集合并覆盖 13 种古典常用乐器 (弦乐 vn、va、vc、db; 木管 fl、ob、cl、sax、bn; 铜管 tpt、tbn、hn、tba), 总帧率 100 Hz (帧间隔 10 ms)。本文同时考虑两种评测口径: **单声部口径**把每条声部独立分轨当作独立样本, 合并 4 个数据集后按曲名 80:20 划分得 33 条测试声部轨, 是本文主结果的默认评测设置; **多声部口径**把同一曲目的所有声部并行进入模型, 由于 PHENICX 中存在同一声部内多件乐器加倍演奏的情况无法按声部隔离, 故多声部实验仅用 URMP、Bach10、TRIOS 三个数据集, 合并 58 首曲目, 按曲名 80:20 划分得 12 首测试曲、共 43 条测试声部轨, 用于检验跨声部交互模块的真实增益, 详见 §V.1.7。

4.1.2 数据勘探 (预处理)

每条音轨经如下流水线: 从原始 wav 中按 10 ms 帧间隔重采样得到帧网格; 用 CREPE^[8] 提取帧级 f_0 并以人工核对的 ground-truth 校正; 用 STFT 短时窗口计算帧级 RMS, 进一步取对数域得到 log amp; 从同步 MIDI 文件解析每个音符的 onset、offset、pitch、velocity, 并按 100 Hz 网格生成与音频对齐的帧级音符序列。划分严格按曲名以 80:20 进行, 同一首曲子的所有声部要么全部在训练集、要么全部在测试集, 既避免同一作品的不同乐器版本跨集出现, 也杜绝跨声部信息泄漏。

4.1.3 数据存储 (如有)

每条音轨独立存为一个 data.npz 文件, 字段包括 notes ($N \times 4$ 的音符数组, 每行为 onset、offset、pitch、velocity 四元组)、f0 (帧级基频 Hz, 长度 T 的浮点数组)、amp (帧级线性域振幅, 长度 T 的浮点数组)、hop_time (帧间隔 0.01 秒) 与 sr (原始音频采样率)。这种以单条音轨为粒度的存储方式, 让训练、验证、可视化都能以音轨为最小可寻址单元, 既便于按曲名划分训练测试集, 也便于在评测阶段做逐曲、逐乐器族的聚合分析。训练时数据加载器按曲目随机抽样, 每条音轨按 5 秒 (500 帧) 等长片段切片喂入

模型, 同时记录每个 batch 内每个片段所属的曲名与乐器, 以便在线计算逐乐器族指标。

4.2 分析算法

4.2.1 算法思想

演奏信息模型的核心问题是: 从稀疏的乐谱事件中预测稠密的演奏控制信号。决定一个音符如何被演奏的信息来自三个时间尺度: 音符本身 (是否发声、音高、起音与衰减阶段)、所在局部旋律 (上下行、节奏紧密程度)、所在乐句结构 (开头与结尾、高潮位置)。据此构造 20 维输入特征向量, 分为三层金字塔: 音符层 6 维、局部层 6 维、全局层 5 维, 另以 3 维乐器族独热统领三层, 见图 1。输出端则把 f_0 视为 81 类分类问题 (因为音高偏差是离散的 MIDI 半音), 把 amp 视为带音符感知头的回归问题 (尊重音符是 amp 的天然分段单位这一先验)。

进一步地, 一个声部该多响理论上可能受到同时发声的其他声部的影响 (例如主旋律放开、伴奏收敛)。为检验这一可能性, 本文在 Mamba 编码器与 GRU 之间预留一段沿声部维作用的跨声部交互模块, 让每个声部表示在需要时能依据其他声部被重加权; 当只有一个声部输入 ($S = 1$) 时该模块自然退化为恒等映射, 整套架构在单声部与多声部两种口径下统一工作。整体张量流见图 2。

4.2.2 算法步骤

演奏信息模型 输入预处理对每帧从 MIDI 派生图 1 所示的 20 维特征向量 (音符层 6 维、局部层 6 维、全局层 5 维、乐器族独热 3 维); 帧级序列编码将各声部特征向量经线性投影后, 送入权重共享的双向 Mamba 编码器 (隐藏维 128, 6 层), 沿时间维高效捕获长程双向依赖; 跨声部交互在 Mamba 编码器输出之上插入沿声部维 S 作用的交互模块, 本文实现声部维多头自注意力、多深度交替 (时序卷积与声部维注意力交替堆叠) 与 FiLM 式聚合调制三种变体, 其中 FiLM 变体取其他声部表示的掩码均值经两层 MLP 产生逐通道仿射系数 (γ, β) , 对本声部特征 $\mathbf{h}$ 作

$$\text{FiLM}(\mathbf{h}) = (1 + \gamma) \odot \mathbf{h} + \beta \quad (1)$$

形式的特征级调制, 输入声部数 $S = 1$ 时该模块自然退化为恒等映射, 整套架构无需修改即可处理任意声部数; 跨时序回归再经双向 GRU (单向隐藏维 256, 2 层, 双向拼接输出 512 维) 做最后一段时序整合。双头解码部分中: f_0 头输出 81 维音高 logits $\mathbf{z}_t$, 但其预测目标并非 MIDI 上已经标注的绝对半音, 而是音符内部及音符过渡处的音分级偏移 (± 200 音分以内, 步长 5 音分)、滑奏与颤音的频率轨迹、以及乐句末尾弱信号段的稳定性, MIDI 绝对音高直接由特征注入并不计入 81 类预测; 推理时对 logits 取 softmax, 以

逐帧 20 维乐谱特征的完整构成		
维	特征	含义
基础音符状态		
1	发声指示	该帧是否发声 (0/1)
2	归一化音高	MIDI 音高 / 127
3	音符内位置	帧在所属音符内的相对位置 (0-1)
4	起音后时间	$\log(1+t)$, t 为距起音的秒数
5	起音邻域	距音符起音 $\pm$ 固定半径帧内为 1
6	收音邻域	距音符收音 $\pm$ 固定半径帧内为 1
局部音符上下文		
7	音符密度	± 0.5 s 窗内活跃音符数 (归一化)
8	音高方向	与前一音符的音高差 / 12 (带符号)
9	音程大小	与前一音符音高差的绝对值 / 24
10	前置休止	与前一音符的间隔 (对数; 乐句边界信号)
11	局部音高趋势	± 5 音符窗内音高回归斜率 / 12
12	节奏规整度	± 3 音符窗内 IOI 标准差/均值 (rubato 指标)
乐器族独热		
13	弦乐	vn / va / vc / db 为 1
14	铜管	tpt / tbn / hn / tba 为 1
15	木管	fl / ob / cl / sax / bn 为 1
乐谱结构上下文		
16	音域位置	$(p - p_{\min}) / (p_{\max} - p_{\min})$, 逐轨
17	乐句位置	乐句内相对位置 (0-1; 以 >0.3 s 间隔切分乐句)
18	音符时长比	时长 / ± 5 音符均值 (上限 3.0)
19	累计音高方向	连续同向音高变化的累计量 / 12
20	连断比	± 3 音符窗内 发声/(发声+休止)

图 1: 20 维输入特征空间的三层金字塔结构。音符层 6 维捕捉单音的基础属性, 局部层 6 维覆盖前后 0.5 秒或 5 个音符的旋律走向与节奏密度, 全局层 5 维刻画整段乐句的轮廓与连断特征; 3 维乐器族独热向量统领三层, 在编码阶段就向模型注入乐器特异性。




图 2: 统一模型的主架构与张量流。20 维乐谱特征经摊平后, 依次经过各声部权重共享的双向 Mamba 编码器 ($d=128$, 6 层)、跨声部交互模块 (沿声部维 S)、双向 GRU (输出 512 维), 再并列分叉到 f_0 头与 amp 头。当 $S=1$ 时跨声部模块自然退化为恒等映射, 整套架构对任意声部数都直接成立。

软取偏移叠加音符基准音高还原 Hz,

$$\hat{f}_{0,t} = f_t^{\text{nom}} \cdot 2^{\Delta c_t / 1200}, \quad \Delta c_t = \sum_{j=1}^{80} (\text{softmax } \mathbf{z}_t)_j c_j, \quad (2)$$

其中 f_t^{nom} 为该帧所在音符的 MIDI 基准音高 (Hz), c_j 为第 j 个偏移桶的中心 (音分); amp 头采用 note-aware 设计, 先在帧级回归预测 log amp, 再以音符为单位聚合并平滑。模型总可训练参数 7.66 M。训练目标在对数域组合多项,

$$\mathcal{L} = \mathcal{L}_{f_0} + \lambda_1 \mathcal{L}_{\log}^{\text{Huber}} + \lambda_2 (1 - r) + \lambda_3 \mathcal{L}^{\text{grad}} + \lambda_4 \mathcal{L}^{\text{ms}}, \quad (3)$$

其中 $\mathcal{L}_{f_0}$ 为 voiced 帧上的 81 类交叉熵, $\mathcal{L}_{\log}^{\text{Huber}}$ 为对数振幅 Huber 项, r 为预测与真值的逐轨 Pearson 相关 (见式 (5)), $\mathcal{L}^{\text{grad}}$ 为时间梯度项, $\mathcal{L}^{\text{ms}}$ 为按拍聚合的多尺度 MSE 项, 各权重 λ_i 为配置量; 优化器为 AdamW。

4.2.3 伪代码

演奏信息模型 训练流程见算法 1。

Algorithm 1 演奏信息模型训练流程

Require: 训练集 $\mathcal{D}_{\text{train}} = \{(\text{notes}_v, f_{0,v}, \text{amp}_v)\}_{v=1}^S$, 总轮数 E , 学习率 η

- 1: 初始化模型参数 θ (Mamba 编码器 / 跨声部交互 / GRU / f_0 头 / amp 头)
- 2: **for** epoch = 1 **to** E **do**
- 3: **for** batch (notes, f_0 , amp) **IN** $\mathcal{D}_{\text{train}}$ **do**
- 4: $\text{feat} \leftarrow \text{NotesToFrameFeatures}(\text{notes})$ $\{S \times T \times 20$ 三层金字塔特征 $\}$
- 5: $\mathbf{h} \leftarrow \text{BiMamba}(\text{LinearProj}(\text{feat}))$ $\{S \times T \times 128$, 权重共享, 6 层 $\}$
- 6: $\mathbf{h} \leftarrow \text{CrossVoiceInteraction}(\mathbf{h})$ $\{\text{沿声部维 } S \text{ 交互; } S=1 \text{ 时恒等}\}$
- 7: $\mathbf{h} \leftarrow \text{BiGRU}(\mathbf{h})$ $\{S \times T \times 512$ (2 层, 单向隐 256, 双向拼接) $\}$
- 8: $\hat{f}_{0\logits} \leftarrow \text{F0Head}(\mathbf{h})$ $\{S \times T \times 81\}$
- 9: $\hat{\text{amp}} \leftarrow \text{NoteAwareAmpHead}(\mathbf{h}, \text{notes})$ $\{S \times T\}$
- 10: $L_{f_0} \leftarrow \text{CrossEntropy}(\hat{f}_{0\logits}, f_0\text{-bins})$ $\{\text{仅 voiced 帧}\}$
- 11: $L_{\text{amp}} \leftarrow \text{Huber}(\hat{\text{amp}}, \text{amp}) + 0.3 L_{\text{ms}} + 0.3 L_{\text{corr}} + 0.2 L_{\text{grad}}$
- 12: $L \leftarrow L_{f_0} + 2 L_{\text{amp}}$
- 13: $\theta \leftarrow \text{AdamW}(\theta, \nabla_{\theta} L, \eta)$
- 14: **end for**
- 15: 在 $\mathcal{D}_{\text{test}}$ 上评测 amp_corr; **IF** amp_corr 创新高 **THEN** 保存当前 θ 为最优检查点 θ^*
- 16: **end for**

Ensure: 最优检查点 θ^*

5 实验结果及分析

5.1 演奏信息模型

5.1.1 评测指标

本文使用两组互补的评测指标。帧级 f_0 以原始音高准确率 (RPA) 评估, 定义为发声帧上预测音高与真值偏差在 50 音分以内的帧占比,

$$\text{RPA} = \frac{\sum_t v_t \mathbf{1}(|1200 \log_2(\hat{f}_{0,t}/f_{0,t})| \leq 50)}{\sum_t v_t}, \quad (4)$$

其中 $v_t \in \{0, 1\}$ 为发声指示。这一指标在文献中被广泛接受, 也能与 CREPE^[8]、pYIN^[9] 等 f_0 提取工具的官方报告直接对照。帧级振幅以预测序列 $\hat{a}$ 与真值序列 a 之间的逐轨 Pearson 相关系数 r 评估, 先逐轨计算再跨轨平均,

$$r = \frac{1}{K} \sum_{k=1}^K \frac{\sum_t (\hat{a}_t^{(k)} - \bar{\hat{a}}^{(k)}) (a_t^{(k)} - \bar{a}^{(k)})}{\sqrt{\sum_t (\hat{a}_t^{(k)} - \bar{\hat{a}}^{(k)})^2} \sqrt{\sum_t (a_t^{(k)} - \bar{a}^{(k)})^2}}, \quad (5)$$

其中 K 为音轨数, $\bar{\cdot}$ 表示对该轨所有帧取均值。同时在线性域与对数域两种空间下报告: 线性域上 Pearson 反映模型对绝对响度变化的捕获能力, 对数域上则更接近人耳的对数感知特性, 也更对齐演奏者对“渐强渐弱”的主观刻度。逐轨先算再跨轨平均的聚合方式比逐帧聚合更稳健, 能避免静音段对相关系数的稀释作用。

5.1.2 主要结果

本文在两套评测口径下分别报告主要结果, 二者使用同一套架构与同一套训练流程 (300 个 epoch, 4 个随机种子, 多种子均值 $\pm$ 标准差汇报)。

单声部口径 (4 个数据集合并, 33 条测试声部轨, 跨声部交互模块取恒等映射): 模型达到帧级 f_0 原始音高准确率 $\text{RPA} \approx 94.6\%$, 中位音分误差约 11.7 cents, 线性域 amp Pearson 相关 0.671 ± 0.005 。

多声部口径 (3 个数据集合并, 43 条测试声部轨, 跨声部交互模块取 deep 多深度交替变体): $\text{RPA} \approx 92.5\%$, amp Pearson 0.615 ± 0.041 。

两套口径的整体均值差异主要来自测试集乐器分布: 多声部 43 条声部轨中弦乐 21、木管 12、铜管 10, 弦乐占比 (49%) 高于单声部测试集 (15/33 = 45%), 而弦乐又是可预测度最低的族 (详见 §V.1.5、§V.1.7), 整体均值被相应拉低。两套口径在乐器内可预测度数值上保持一致, 跨声部交互的真实增益、稳定迁移与统一模型证据见 §V.1.7。

下文对单声部主结果做共性分析: f_0 的 RPA 接近 100% 的量纲上限, 说明基频在 MIDI 半音约束之下基本可被完整预测; 偶发的 5% 余差大多落在乐句末尾的弱信号段与两个半音之间的滑奏过渡, 这两类位置上 f_0 标注本身也不稳定, 因此不构成模型的真

实瓶颈。振幅的 Pearson 在 0.67 一线, 表明可预测部分主要由乐句轮廓与音符内动态包络支撑, 这两类信号都强烈依赖于 MIDI 中可直接读取的乐句结构与音符位置; 残差中较高频段的微观动态 (例如颤音引起的振幅调制 AM、乐句中段的力度微抖、弓压与气流的连续起伏) 则受真实演奏的不可观测因素影响, 不可由 MIDI 单独决定。该残差可能来自三种成分: (a) 跨架构都未能越过的经验饱和点, (b) 默认指标自身放大特定噪声成分的产物, (c) 人耳真正可感知的演奏表达流失, §V.1.3 配置扫描、Oracle 负结果、集成误差相关与多指标重构四项分析依次定位, 再由主观听感实验作收束。

5.1.3 经验饱和点的稳健性

本节四项分析 (配置扫描、Oracle 负结果、集成误差相关与多指标重构) 均在前述**单声部口径**下进行 (33 条测试轨), 用以刻画振幅 Pearson 在仅乐谱设置下的经验饱和带; 与多声部口径的对照见 §V.1.7。

配置扫描 为判断振幅 Pearson 的饱和是否仅为单一模型的不足, 本文沿四条干预轴对该任务做了系统配置扫描, 共覆盖 16 个方向类、累计 200 余个有记录的训练配置: 第一条轴是架构与容量 (双向 GRU、Transformer、S4D、Mamba, 参数量 1 M 至 30 M); 第二条轴是损失与训练目标 (相关性损失、排序损失、多分辨率谱风格损失、力度感知教师蒸馏、异方差/瞬态加权损失、随机权重平均、平滑目标训练); 第三条轴是目标与特征变换 (高斯平滑、秩、CDF 均衡、巴特沃斯低通等目标表示, 小波/经验模态分解/陷波/可学习滤波等去噪范式, 逐曲归一化、ADSR 先验, 合成与分布外语料扩充); 第四条轴是集成与 oracle (异构多架构集成、乐谱力度注入、真值 f_0 oracle)。每个方向取该方向最优配置后 (图 3), 全部 16 个最优振幅 Pearson 均落在 $r \in [0.60, 0.69]$ 的窄带内, 其中 13/16 落在单模型基线 ± 0.02 以内, 没有任何一条方向单独突破 0.70。这一一致性显示, 在本文数据、特征与默认评测口径下, 振幅 Pearson 在 ≈ 0.69 一线呈现稳定饱和, 是当前设置下跨架构、跨损失、跨特征变换共享的可预测性瓶颈。该饱和是本文所选数据与特征空间下的经验现象, 不直接外推为“任务理论上限”。




图 3: 16 个主要方向类系统扫描下各方向所达的最优原始帧级振幅 Pearson (每类一柱)。虚线参考线为四种子单模型基线 ($r \approx 0.671$) 与 9 成员异构集成 ($r \approx 0.687$)。所有方向聚拢在 $r \in [0.60, 0.69]$ 的窄带内, 其中 13/16 落在单模型基线 ± 0.02 之内。

Oracle 负结果 配置扫描确立了饱和点跨架构稳健, 但并未排除”模型缺失某一关键输入”的可能。本文为此对两个最有力的候选缺失特征直接做 oracle 检验。(i) 音高耦合 oracle: 测试时把模型预测的 f_0 偏差替换为真值 f_0 导出的偏差, 这一干预把 f_0 RPA 从 94.6% 提至 98.0%, 颤音深度误差大致减半, 但振幅 Pearson 仅比同种子基线高 $\Delta r = +0.002$, 完全落在 ± 0.005 的种子噪声以内, 说明音高耦合信息不是缺失的振幅信号。(ii) 乐谱力度 oracle: 从 URMP、PHENICX、TRIOS 的源 MIDI 重抽含有与录音无关的非平凡力度标记的力度轨, 作为第 21 维输入加入特征向量, 同样四种子训练得振幅 Pearson 0.666 ± 0.008 , 与 20 维基线统计上分不开 ($\Delta r = -0.005$, 处于合并种子噪声内)。两个 oracle 都未抬动饱和点, 这说明残差更可能来自演奏者层面的响度意图 (GERM 模型^[6] 中的表达与运动分量), 该意图在 MIDI 乐谱中没有与乐器无关的编码, 因此本来就在仅乐谱口径之外; 当然, 本文仅检验了 f_0 与 MIDI 力度两个最有力的候选缺失特征, 并不构成对所有可能输入的穷尽排除。

集成误差相关 若饱和点确为跨架构共享, 它应在异构集成的误差相关上留下可量化的痕迹。这里借助 Perrone 与 Cooper 的集成方差缩减框架^[13]: 对 N 个预测器取平均, 记单成员均方误差均值为 $\bar{E}$ 、成员间误差两两相关为 ρ_e , 集成均方误差为

$$E_{\text{ens}} = \bar{E} \frac{1 + (N-1)\rho_e}{N}, \quad \frac{1}{N} \leq \frac{E_{\text{ens}}}{\bar{E}} \leq 1, \quad (6)$$

归一化后取值在 $1/N$ (完全不相关, 线性下降) 与 1 (完全相关, 毫无改进) 之间; ρ_e 越接近 1, 平均能消去的方差越少。本文据此构造一个由 9 个架构差异显著的成员组成的异构集成 (蒸馏 Mamba 基线加上 8 个不同骨干、不同归一化、不同训练长度的检查点), 在 33 条测试轨上把逐帧对数振幅残差汇成一池, 对全部 $\binom{9}{2} = 36$ 对成员算两两误差相关, 得非对角平均误差相关 $\rho_e \approx 0.962$ (成对范围 $[0.912, 0.982]$)。取 $N = 9$ 、 $\rho_e = 0.962$ 代入式 (6), 集成均方误差相对单模型缩减因子约 0.966, 即平均仅能消去单模型平方误差方差的约 3.4%。实测后验印证: 相对四种子单模型基线 0.671 ± 0.005 , 完整 9 成员异构集成达 $r = 0.687$, $\Delta r \approx +0.016$, 与 ρ_e 所允许的方差收缩预算高度吻合。集成几乎无法降低残差, 说明该残差是跨归纳偏置共享的, 而非某个特定模型独有的错配。

多指标重构 默认的帧级线性 Pearson 容易被最响的几帧、子音符相位漂移、逐录音的话筒增益主导, 把音频内在因素与乐谱可恢复的表达混入同一刻度。本文不重训, 仅在六个对预测与真值对称施加的互补指标下重新评测同一组预测 (表 1): 对数振幅 Pearson 消除线性 RMS 对最响帧的偏向; Sones 感知响度 Pearson^[14] 用 Zwicker 心理声学模型, 与对数结果交叉验证不是单一变换的人为产物; $\sigma = 1$ s 高斯平滑工作在乐句尺度上, 跳过承载多数音频噪声的子音符颗粒; 逐轨秩 ($\sigma = 10$ s) 进一步抵消乐谱不可预测的逐录音增益偏移, 提供秩尺度诊断上界; 逐音符 Pearson 在每个标注音符窗内聚合, 给出正交的逐事件一致性。9 成员集成在六个指标下的 Pearson 从默认线性 RMS 的 0.687 单调升至秩尺度的 0.900, 三步抬升分别约为对数 +0.14、 $\sigma = 1$ s 乐句 +0.03、逐轨秩 +0.05, 各步均有清晰物理解释。这意味着默认 0.69 不是模型能力的绝对刻度, 而是该指标自身放大特定噪声成分后的产物; 但默认与重构指标之差具体对应何种丢失 (任何 MIDI 条件模型都不可恢复的音频内在噪声, 还是真正被漏掉的演奏表达), 仅靠指标本身无法判定, 由主观听感实验作答。

表 1: 同一组预测在六个互补振幅指标下的振幅 Pearson

指标	单模型 (4 种子)	9 成员异构集成
线性 RMS Pearson (默认)	0.671 ± 0.005	0.687
对数振幅 Pearson	0.815 ± 0.004	0.823
Sones 感知响度 Pearson	0.728 ± 0.007	0.747
乐句 Pearson ($\sigma = 1$ s)	0.841 ± 0.008	0.855
秩 Pearson ($\sigma = 10$ s, 诊断上界)	0.810 ± 0.095	0.900
逐音符 Pearson	0.394 ± 0.017	0.420

5.1.4 主观听感实验

默认指标约 0.69 与重构指标约 0.90 之间究竟丢失了什么？本文用一项 $N = 26$ 的强制二选一 A/B 听感实验作答。实验材料选取了振幅可预测度最低的乐器族（弦乐，见 §V.1.5 表 3）中的 20 秒小提琴片段，用同一 8 谐波加性合成器分别用真实 (f_0, amp) 与模型预测的 (f_0, amp) 驱动，让被试在哪一版噪声更多、哪一版表达更多两个维度上做选择；在最难的乐器族上验证听感结论，等价于对所有乐器给出相对保守的下界。结果见表 2：噪声维度 26 名被试全部选择真实版 ($p \approx 3 \times 10^{-8}$)；表达维度则接近随机 (15:11, $p \approx 0.56$)。在该样例与该合成器设置下，被试并未稳定区分真实与预测版本的表达差异，这一结果初步说明默认 Pearson 未捕获的部分未必全部对应可听感的演奏表达损失；但样本量与片段长度均较小，是否能外推到所有乐器、所有曲风、所有下游合成器，仍需更大规模、更多片段的主观研究进一步验证。

表 2: 强制二选一 A/B 听感研究 ($N = 26$)

维度	A (真实包络)	B (预测包络)	p 值
噪声更多	26 (100%)	0 (0%)	3×10^{-8}
表达更多	15 (58%)	11 (42%)	0.56

5.1.5 逐乐器族分析

把 33 条单声部测试轨按乐器族划分：铜管 ($n = 9$, tpt、tbn)、木管 ($n = 9$, fl、ob、cl、sax、bn)、弦乐 ($n = 15$, vn、va、vc)，9 成员异构集成在默认线性 RMS 指标下的逐族振幅 Pearson 见表 3：铜管 0.857、木管 0.702、弦乐 0.575，三族的 95% 自助置信区间互无重叠，族间差距稳健，不是小样本假象。需说明的是，§IV.1.1 列出的 13 种乐器是四个数据集合并后的总覆盖范围，按曲名 80:20 划分后，db、hn、tba 三种乐器恰好被划入训练集而未进入这 33 条单声部测试轨，因此本节族表不列这三种；多声部口径下 (43 条声部轨) 由于划分粒度从声部轨改为曲目，这三种乐器进入了测试集，详见 §V.1.7 表 5。这一排序具有清晰的物理解释：弦乐 amp 曲线中含有较高频段的颤音调幅成分^[12]，这一成分由演奏者的弓速变化与左手揉弦控制，在 MIDI 乐谱中没有对应记号，因而不可由 MIDI 单独推断；木管的振幅则由气流压力与音孔切换共同塑形，其中音孔切换由乐谱决定可被预测，气流压力的连续起伏则需要演奏者意图作为额外输入；铜管的振幅主要由气压包络与音符结构决定，与 MIDI 的关联度最高，因此可预测度最强。由于弦乐处在最低端，主观听感实验也正是为此特意选取弦乐（小提琴）作答，以验证最难的乐器族上模型预测仍能承受听感校验。长远来看，给弦乐单独引入颤音生成模块，或者把演奏者意图作为额外输入，可能是进一步提升弦乐振幅可预测度的可行路径。

表 3: 单声部口径下乐器族振幅 Pearson (33 条测试轨, 9 成员异构集成)

乐器族	测试声部数	amp Pearson
铜管 (tpt、tbn)	9	0.857
木管 (fl、ob、cl、sax、bn)	9	0.702
弦乐 (vn、va、vc)	15	0.575

5.1.6 方差频带分解

逐乐器族分析已经把残差落到具体乐器, 进一步本文沿频率方向定位残差所占的物理通道。用 4 阶巴特沃斯滤波器^[15] 把测试集对数振幅目标分到四个有物理动机的频带: 子乐句带 (< 0.5 Hz, 含逐轨录音增益与乐句级动态)、音符包络带 ($0.5-3$ Hz)、颤音调幅带 ($3-10$ Hz)、高频带 ($10-48$ Hz, 弓/气/话筒噪声)。测试轨上真值对数振幅的方差占比依次约为 48%、30%、10%、2% (余下约 10% 为有限滤波过渡带的频带间泄漏), 9 成员异构集成对真值的逐带 Pearson 为子乐句带 0.895、音符带 0.759、颤音带 0.631、高频带 0.230 (图 4)。子乐句带方差占比最高且被捕捉得最好, ”模型输在慢分量” 的流行直觉被实测否定; 颤音带尽管只占真值方差约 10%, 却承载了约 15% 的总残差均方误差。定义某频带的过表征比为其残差份额与方差份额之比,

$$\rho_{\text{band}} = \frac{\text{MSE}_{\text{band}} / \sum_b \text{MSE}_b}{\sigma_{\text{band}}^2 / \sum_b \sigma_b^2}, \quad (7)$$

按未取整的频带份额计, 颤音带 $\rho_{\text{band}} \approx 1.4$, 指向 $3-10$ Hz 是主导振幅 Pearson 经验饱和的频带。作为稳健性检验, 把固定的巴特沃斯频带换成数据自适应的变分模态分解^[16] (令 $K = 4$ 个模态的中心频率从信号中自行发现), 发现的模态 (平均 0.00、1.86、5.52、20.67 Hz) 与四个手选频带重合, 逐带 Pearson (0.85、0.70、0.48、0.17) 定性一致, 说明四带分解不是所选滤波截止的人为产物。颤音带恰好对应弓速变化与左手揉弦控制^[12], 在 MIDI 乐谱中没有对应记号, 与逐乐器族中弦乐显著落后于铜管的实测排序完全对得上。




图 4: 测试集对数振幅四个频带的方差占比 (柱, 左轴) 与 9 成员异构集成对真值的逐带 Pearson (线, 右轴)。子乐句带方差占比最高且预测最好, 颤音带方差占比虽小却主导残差, 高频带最难预测。

5.1.7 多声部扩展

跨声部交互的动机与结构 前述单声部实验把每条声部独立预测, 完全不利用其他声部信息。实际演奏中, 一个声部的响度分配理论上可能受到同时发声的其他声部的影响 (例如主旋律放开、伴奏收敛)。本文据此检验在统一骨干上加入跨声部交互模块的真实增益, 设四个变体作严格对照: `none` 用恒等映射替代该模块, 让各声部独立运行 (零交互对照基线); `attn` 沿声部维做一次多头自注意力; `deep` 把时序卷积与声部维注意力交替堆叠三层, 在多个深度上反复交互; `film` 由其他声部聚合得到的上下文产生逐通道仿射系数 (式 1), 以特征级仿射调制本声部表示。四个变体共用同一骨干, 任何差异只能归因于交互机制本身。多声部实验使用 URMP、Bach10、TRIOS 三个数据集 (58 首曲目, 43 条测试声部轨), 训练 300 个 epoch、4 个随机种子。

跨声部交互的消融 §V.1.2 的多声部主结果 (0.615 ± 0.041) 取的是 `deep` 多深度交替变体。在 4 个随机种子的配对检验下 (表 4), 无交互基线 amp Pearson 为 0.580 ± 0.035 , 加入 `deep` 交互后升至 0.615 ± 0.041 , 增益 $+0.035$, 配对 $t \approx 1.10$, 在当前数据规模下尚未达到统计显著。这一接近零的增益与单声部经验饱和点的结论彼此呼应: 跨声部协同所需的额外信息, MIDI 乐谱同样不足以承载, 即便显式引入交互机制, 也只能换来配对检验未达显著的小幅改进。跨声部交互并不会破坏整体性能, 整体走势依然贴近统一骨干的预测能力, 可以作为下游音色合成的稳定输入。

表 4: 跨声部交互模块的消融结果 (43 条声部轨, 4 种子, 振幅 Pearson)

变体	均值 $\pm$ 标准差	t 值
none (恒等映射)	0.580 ± 0.035	基线
attn (单次声部维注意力)	0.605 ± 0.038	≈ 0.85 (n.s.)
deep (多深度交替)	0.615 ± 0.041	≈ 1.10 (n.s.)
film (聚合调制)	0.610 ± 0.039	≈ 0.95 (n.s.)

多声部逐乐器族分布 多声部 43 条测试声部轨上的逐乐器族 Pearson (表 5) 仍呈”铜管 > 木管 > 弦乐”的稳定排序 (0.825/0.603/0.522), 与单声部口径下的 0.857/0.702/0.575 完全同向; 进一步逐乐器汇总 (表 6) 显示同族内部各乐器之间的相对位次也保持稳定, 弦乐内部的 vn、va、vc、db 互相邻近, 铜管内部的 tbn、hn、tpt、tba 互相邻近。跨两种评测口径的族序与乐器内可预测度数值一致, 是本文整体 Pearson 数值最关键的支撑事实, 直接决定了 §V.1.8 关于结论适用范围的判断。

表 5: 多声部口径下乐器族振幅 Pearson (43 条声部轨, 4 种子)

乐器族	测试声部数	amp Pearson
铜管 (tpt、tbn、hn、tba)	10	0.825 ± 0.037
木管 (cl、sax、bn)	12	0.603 ± 0.030
弦乐 (vn、va、vc、db)	21	0.522 ± 0.050

稳定迁移与模型统一 架构上, 本文模型在 $S = 1$ 时跨声部模块退化为恒等映射, 因此同一套权重可无修改地处理独奏与合奏两种输入; 但架构本身只保证可运行, 不保证性能稳定, 后者仍需实验确认。把只在合奏数据上训练 (从未见过单声部输入) 的多深度模型, 直接以单声部方式喂入第 V.1.2 节的 33 条单声部测试轨, 得振幅 Pearson 0.628、 f_0 RPA 0.906、分族 0.845 (铜管) / 0.607 (木管) / 0.511 (弦乐); 与单声部专用模型基线 (0.671 / 0.946) 仅相差约 0.05, 0.628 也正好落在多深度模型自身的 4 种子区间 0.554–0.641 内。也就是说, 跨两种评测模式 (本联合奏与单声部迁移) 的一致性, 处于该模型自身的种子噪声包络之内。实验表明这种退化在本文测试集上并未造成灾难性性能下降, 可作为统一架构可行性的初步证据; 但本结论仅基于单一检查点与本文测试集, 在更大规模合奏数据或不同分布下的稳定性, 仍需进一步检验。

表 6: 多声部口径下逐乐器振幅 Pearson (4 种子, 按均值降序)

乐器	中文名	乐器族	测试声部数	amp Pearson
tbn	长号	铜管	3	0.867 ± 0.025
hn	圆号	铜管	2	0.823 ± 0.029
tpt	小号	铜管	4	0.801 ± 0.062
tba	大号	铜管	1	0.800 ± 0.115
cl	单簧管	木管	5	0.670 ± 0.057
sax	萨克斯	木管	4	0.599 ± 0.065
va	中提琴	弦乐	4	0.581 ± 0.118
vc	大提琴	弦乐	3	0.561 ± 0.069
db	低音提琴	弦乐	2	0.499 ± 0.058
vn	小提琴	弦乐	12	0.497 ± 0.114
bn	巴松	木管	3	0.497 ± 0.049

5.1.8 适用范围说明

需要明确, 本节所报告的整体数值 (单声部 RPA $\approx 94.6\%$ 、振幅 Pearson 0.671 ± 0.005 ; 多声部 RPA $\approx 92.5\%$ 、振幅 Pearson 0.615 ± 0.041) 都依赖于本文测试集的乐器分布: 单声部 33 条测试轨中弦乐 15、木管 9、铜管 9, 多声部 43 条测试声部轨中弦乐 21、木管 12、铜管 10, 两套口径下弦乐占比均较高, 因而整体均值被弦乐这一最难的族强烈拉低。真正稳定的量是表 6 中的逐乐器 Pearson, 它由各乐器自身的物理产声机制与 MIDI 之间的信息差距决定 (颤音、气压调控、弓速等不可观测因素), 不依赖于测试集中各乐器各占多少。因此, 若将本文模型迁移到一个铜管比例更高的曲库, 整体 Pearson 会上移; 反过来, 在以弦乐独奏为主的曲库上整体 Pearson 会下移。但每一种乐器自己的可预测度数值基本保持稳定, 主观听感实验也正是为此选取最难的小提琴作答, 以验证这种乐器内部的稳定饱和点确实可以承受听感校验。该乐器内稳定性同样意味着, 后续工作引入更大规模、更高多样性的真实录音时, 主要会改变两表中的族间相对比例与整体均值, 而不会改变本文得到的乐器内可预测度排序及其物理解释。此外, 本文数据规模 (58 首、约 88 分钟、主要为西方古典室内乐) 仍较小, 上述结论是否可外推到非西方音律体系、爵士摇摆等其他演奏风格, 仍需更大规模的真实录音进一步验证。

5.2 TODO

TODO

6 实例展现 (Demo 截图等)

7 总结和不足

7.1 工作总结

针对演奏信息模型这一关键环节, 设计了 20 维三层金字塔特征 + 双向 Mamba 与双向 GRU 串联骨干 + 跨声部交互模块 + f_0 分类与 amp 音符感知回归双头的统一架构。单声部口径下基于 URMP、Bach10、PHENICX-Anechoic 与 TRIOS 四个数据集评估 (33 条测试声部轨), 模型在 4 种子均值下达到 f_0 RPA 约 94.6%、amp Pearson 约 0.671 ± 0.005 ; 多声部口径下基于 URMP、Bach10 与 TRIOS 三个数据集评估 (43 条测试声部轨, 跨声部 deep 变体), 达到 f_0 RPA 约 92.5%、amp Pearson 约 0.615 ± 0.041 。模型参数仅 7.66 M, 可作为下游合成的稳定输入。跨声部交互模块的消融显示加入交互带来 +0.035 的边际增益, 多种子配对检验未达显著, 与振幅经验饱和点的结论一致。

7.2 不足

数据规模仍偏小: 单声部口径虽覆盖 13 种西方古典常用乐器, 但多声部口径实际用于跨声部交互检验的数据规模更有限, 且尚未覆盖爵士、电子、流行等其他演奏风格, 对这些风格的迁移能力未验证。模型对长程音乐结构 (如乐章级反复) 的捕获仍依赖统计先验, 在转调或速度突变处的表现有限。跨声部交互模块带来的增益虽与振幅经验饱和点的结论方向一致, 但 0.035 的差值仅由 4 个随机种子估得, 仍需更大规模数据加以确认。与下游合成器的联合训练、以及向更大编制 (四重奏、室内乐) 的扩展, 留作未来工作。

7.3 小组成员与分工

姓名	分工
张景铭	数据集及相关处理工作、演奏信息模型特征与架构设计
TODO	TODO
TODO	TODO
TODO	TODO

参考文献

- [1] J. Engel, L. Hantrakul, C. Gu, and A. Roberts, “DDSP: Differentiable Digital Signal Processing,” in *ICLR*, 2020.
- [2] Y. Wu *et al.*, “MIDI-DDSP: Detailed Control of Musical Performance via Hierarchical Modeling,” in *ICLR*, 2022.
- [3] D. Jeong, T. Kwon, Y. Kim, K. Lee, and J. Nam, “VirtuosoNet: A Hierarchical RNN-based System for Modeling Expressive Piano Performance,” in *ISMIR*, 2019.
- [4] H. Zhang, S. Chowdhury, C. E. Cancino-Chacón, J. Liang, S. Dixon, and G. Widmer, “DExter: Learning and Controlling Performance Expression with Diffusion Models,” arXiv:2406.14850, 2024.
- [5] C. Cancino-Chacón, M. Grachten, W. Goebel, and G. Widmer, “Computational Models of Expressive Music Performance: A Comprehensive and Critical Review,” *Frontiers in Digital Humanities*, vol. 5, art. 25, 2018.
- [6] P. N. Juslin, A. Friberg, and R. Bresin, “Toward a Computational Model of Expression in Music Performance: The GERM Model,” *Musicae Scientiae*, special issue, pp. 63–122, 2002.
- [7] A. Friberg, R. Bresin, and J. Sundberg, “Overview of the KTH Rule System for Musical Performance,” *Advances in Cognitive Psychology*, vol. 2, no. 2–3, pp. 145–161, 2006.
- [8] J. W. Kim, J. Salamon, P. Li, and J. P. Bello, “CREPE: A Convolutional Representation for Pitch Estimation,” in *ICASSP*, pp. 161–165, 2018.
- [9] M. Mauch and S. Dixon, “pYIN: A Fundamental Frequency Estimator Using Probabilistic Threshold Distributions,” in *ICASSP*, pp. 659–663, 2014.
- [10] B. Li, X. Liu, K. Dinesh, Z. Duan, and G. Sharma, “Creating a Multi-track Classical Music Performance Dataset for Multimodal Music Analysis: Challenges, Insights, and Applications,” *IEEE Trans. on Multimedia*, vol. 21, no. 2, pp. 522–535, 2019.
- [11] Z. Duan, B. Pardo, and C. Zhang, “Multiple Fundamental Frequency Estimation by Modeling Spectral Peaks and Non-peak Regions,” *IEEE Trans. on Audio, Speech, and Language Processing*, vol. 18, no. 8, pp. 2121–2133, 2010.

- [12] M. Mellody and G. H. Wakefield, “The Time-Frequency Characteristics of Violin Vibrato: Modal Distribution Analysis and Synthesis,” *Journal of the Acoustical Society of America*, vol. 107, no. 1, pp. 598–611, 2000.
- [13] M. P. Perrone and L. N. Cooper, “When Networks Disagree: Ensemble Methods for Hybrid Neural Networks,” in R. J. Mammone, ed., *Neural Networks for Speech and Image Processing*. Chapman-Hall, 1993.
- [14] E. Zwicker and H. Fastl, *Psychoacoustics: Facts and Models*, 3rd ed. Springer, 2007.
- [15] S. Butterworth, “On the Theory of Filter Amplifiers,” *Wireless Engineer*, vol. 7, pp. 536–541, 1930.
- [16] K. Dragomiretskiy and D. Zosso, “Variational Mode Decomposition,” *IEEE Trans. on Signal Processing*, vol. 62, no. 3, pp. 531–544, 2014.

TODO